

多源异构数据驱动岗位和能力图谱构建与动态演化分析研究

赛题任务书

题目编号：XH-202621

发榜单位：科大讯飞股份有限公司

周期：3 个月（2026 年 6 月 — 2026 年 8 月）

一、总体任务目标

面向新一代信息技术领域（人工智能、大数据、智能系统、物联网等），设计并开发一套“数据驱动 + 大模型 + 知识图谱”的岗位能力动态演化与分析系统。系统需完成从多源异构数据采集与清洗、新岗位发现与定义、既有岗位能力动态更新、岗位能力全景图谱构建、到简历解析与人岗匹配诊断的全流程闭环，最终实现“静态画像”向“动态感知”的跨越。

核心指标要求：

指标项	目标值
JD 解析准确率	$\geq 90\%$
简历技能要素提取准确率	$\geq 90\%$
人岗匹配准确率	$\geq 90\%$
测试用例（含岗位 JD）	≥ 100 条
单元测试覆盖率	$\geq 60\%$
新岗位发现与定义	≥ 1 个完整案例
既有岗位能力动态更新	≥ 1 个完整案例

系统核心功能涵盖：新岗位发现与定义（含岗位名称、核心职责、必备/加分技能、典型行业应用场景）、既有岗位能力动态更新（含新增/删除/修改能力项标注）、新一代信息技术岗位全景图谱（技能点级粒度，支持按技术栈与级别切换视图）、人岗匹配度诊断与差距分析（支持简历 PDF/Word 解析，提供改进建议与学习路径规划）。

二、技术路线总览

整体技术路线遵循“数据驱动 + 大模型 + 知识图谱”三位一体的核心思路，按照“多源异构数据采集与清洗 → 系统框架搭建 → 大模型信息抽取与实体标准化对齐 → 知识图谱构建 (Neo4j) → 动态演化分析 → 简历解析与人岗匹配”的流水线推进。关键技术包括且不限于：大语言模型 (LLM) + RAG 架构用于信息抽取与幻觉防控、BERT Embedding 用于实体对齐、Neo4j 图数据库用于知识图谱存储与查询、时间序列分析与网络分析用于动态演化研究、LayoutLM 用于简历版面解析、多维度加权匹配算法用于人岗匹配诊断。创新性重点体现在多源异构数据交叉验证解决时滞与噪声问题、基于 RAG + Human-in-the-loop 的能力幻觉防控机制、以及融合时序与网络分析的岗位能力动态演化模型。




图 1 任务划分

多源异构数据驱动的岗位和能力图谱构建与动态演化分析研究 — 技术方案图




图 2 技术方案

三、第一阶段任务 1：数据采集清洗与系统框架搭建

阶段目标：完成多源异构数据的采集、清洗流水线搭建，同时完成系统整体技术架构的设计与基础设施部署，为后续大模型抽取与图谱构建奠定数据与工程基础。

子任务 1.1：多源异构数据采集

目标：构建覆盖互联网公开数据、招聘平台数据、行业数据库的多渠道采集体系，获取与新一代信息技术岗位相关的大量原始数据。

具体内容：针对互联网公开数据（百度、微博、知乎、CSDN 等）进行爬虫采集，重点抓取技术博客、行业报告、职业发展讨论等内容；对接主流招聘平台（Boss 直聘、拉勾、猎聘、智联等）的岗位 JD 数据，覆盖人工智能、大数据、智能系统、物联网等方向的相关岗位信息。

考核指标：招聘 JD 数据覆盖不少于 30 个岗位类型（人工智能、大数据、智能系统、物联网等相关岗位）；用例不少于 10000 条，内容应包括且不限于如下字段：岗位名称、技能、技术栈、行业、学历、项目经验、证书等；数据来源不少于 5 个渠道；建立数据采集日志与溯源机制。

子任务 1.2：数据清洗、去重与标注

目标：建立完整的数据质量控制流水线，解决原始数据中的噪声、重复、时滞和"抄袭"问题，形成高质量数据集。

具体内容：设计并实现数据清洗流水线，包括过滤、规范化、异常值检测、去重（基于 SimHash / MinHash 等算法解决 JD "抄袭"与"通胀"问题）；结合 Human-in-the-loop 机制进行质量校验；对清洗后的数据进行分层采样，构建训练集、验证集和测试集。

考核指标（暂定）：数据采集与清洗报告、清洗后数据有效率 $\geq 90\%$ ；去重精确率 $\geq 90\%$ ；构建包含 ≥ 100 条标准 JD 的测试集。

子任务 1.3：系统整体架构设计与基础设施搭建

目标：完成系统的总体架构设计，搭建开发、训练和部署的基础设施环境。

具体内容：设计模块化系统架构，明确数据采集层、NLP 处理层、知识图谱层、应用服务层、前端展示层的职责划分与接口规范；搭建图数据库（Neo4j）、关系数据库（MySQL）、文档数据库（MongoDB）等存储基础设施；部署大模型推理服务（调用接口）；建立代码仓库、容器化部署方案（Docker）。

考核指标：完成系统架构说明文档（含模块划分图、接口定义）；Neo4j、MySQL、MongoDB 等数据库部署完成并可连通；大模型推理服务可正常调用；代码仓库搭建完成；完成 Docker 基础镜像构建。

阶段交付物：系统架构说明文档、项目代码仓库。

四、第二阶段任务 2：大模型信息抽取、实体标准化与知识图谱构建

阶段目标：基于大语言模型实现岗位 JD 与行业文本中的实体抽取与关系抽取，完成实体标准化对齐，构建新一代信息技术领域的岗位能力知识图谱，并实现新岗位发现与既有岗位能力动态更新功能。

子任务 2.1：大模型驱动的信息抽取

目标：利用大语言模型（LLM）对第一阶段中采集的岗位 JD、技术博客、行业报告等文本进行高精度的命名实体识别（NER）、关系抽取（RE）和事件抽取（EE），提取岗位名称、技能点、职责描述、行业场景、证书要求等核心要素。

具体内容：设计面向岗位领域的 Prompt Engineering 方案，结合 Few-shot / Chain-of-Thought 等策略引导大模型进行结构化信息抽取；采用 RAG（检索增强生成）架构，将待抽取文本与知识库中的已有实体定义进行匹配，降低“幻觉”风险；对抽取结果进行规则后处理与置信度评估，过滤低置信度结果。

考核指标（暂定）：JD 解析准确率 $\geq 90\%$ ；大模型幻觉率 $\leq 5\%$ （基于人工抽样评估）。

子任务 2.2：实体标准化与对齐融合

目标：对多源抽取的实体进行标准化归一，解决同义词、近义词、表述不一致等问题，实现跨数据源的实体对齐与知识融合。

具体内容：构建岗位领域同义词库与本体（Ontology），定义实体类型体系（职位、技能、证书、行业、技术栈等）及关系类型（属于、要求、关联、前置依赖等）；基于语义相似度（BERT Embedding + 余弦相似度）与大模型辅助判定进行实体对齐；实施冲突消解策略（多源投票、时间戳优先、权威源优先），完成知识融合。

考核指标（暂定）：实体对齐精确率 $\geq 90\%$ ；同义词覆盖率 $\geq 90\%$ （对比人工构建的参考词表）；融合冲突解决准确率 $\geq 90\%$ ；形成完整的岗位领域本体定义文档。

子任务 2.3：知识图谱构建与存储

目标：基于 Neo4j 图数据库构建新一代信息技术领域的岗位能力知识图谱，实现图谱的可视化查询与基础分析能力。

具体内容：设计图谱数据模式（实体类型、关系类型、属性定义），将标准化后的实体与关系批量导入 Neo4j；实现图谱的增量更新机制，支持人工新增岗位、技能、关系的动态写入；开发图谱查询 API（Cypher + REST），支持按技术栈、岗位级别、行业领域等多维度检索；构建“技能点”级粒度的能力图谱，支持按技术栈和级别切换视图。

考核指标：图谱覆盖 ≥ 30 个岗位类型；技能点粒度达到具体技术框架/工具/方法级别；完成新一代信息技术岗位全景图谱可视化界面。

子任务 2.4：新岗位发现与既有岗位能力动态更新

目标：基于知识图谱与多源数据分析，实现新兴岗位的自动发现与定义，以及既有岗位能力要求的动态感知与更新。

具体内容：设计新岗位发现算法，基于聚类分析（社区发现）、趋势异常检测、技能组合 novelty 评估等方法识别正在萌芽但尚未标准化的新岗位；对新发现的岗位自动生成定义（含岗位名称、核心职责、必备技能、加分技能、典型行业应用场景），支持人工审核与优化；对既有岗位（如 Java 开发工程师），通过时间序列对比分析识别能力要求变化，标注新增/删除/修改的能力项，提供更新说明与数据源依据。

考核指标：完成 ≥ 1 个新岗位的发现与定义（经人工评审认可）；完成 ≥ 1 个既有岗位的能力动态更新案例（含完整变更日志与数据溯源）；能力更新贴合企业实际需求（人岗匹配）的准确率 $\geq 80\%$ 。

阶段交付物：信息抽取模型与 Prompt 方案、实体标准化词表与本体定义、Neo4j 知识图谱（含可视化）、图谱查询说明文档。

五、第三阶段任务 3：动态演化分析、简历解析与人岗匹配

阶段目标：实现岗位能力的动态演化分析与可视化展示，开发高精度简历解析模块，完善人岗匹配诊断与差距分析功能，进行系统整体集成、测试与优化。

子任务 3.1：动态演化分析

目标：对知识图谱进行时序建模与趋势分析，揭示岗位能力的动态演化规律，提供前瞻性的技能趋势预测。

具体内容：构建时间序列模型，按季度/月度粒度分析各岗位技能需求的变化趋势（趋势性变化、周期性波动、异常值检测）；（暂定）进行网络分析，计算节点度中心性、介数中心性、聚类系数，运用社区发现算法识别技能簇的演化；（暂定）开发能力标签演化趋势分析模块，追踪"AI Agent"大模型""RAG""ML""NLP"等关键能力标签的兴衰变化；（暂定）基于分析结果预测未来 6-12 个月的技能需求趋势，为人才培养与职业规划提供参考。

考核指标（暂定）：时间序列分析覆盖 ≥ 4 个时间周期（如 2024Q1—2025Q4 或更长）；完成能力标签演化趋势可视化报告；动态演化分析模块可在线运行并支持交互式探索。

子任务 3.2：简历解析（PDF / Word）

目标：开发高精度简历解析模块，支持 PDF 和 Word 格式的简历，提取技能要素、教育背景、项目经验等关键信息。

具体内容：设计简历结构化解析流水线，包括文档格式识别与转换、版面分析（基于 LayoutLM 或类似文档理解模型）、文本提取与段落分割、命名实体识别（技能、学校、公司、项目等）。

考核指标：简历技能要素提取准确率 $\geq 90\%$ ；支持 PDF 和 Word 两种主流格式；完成简历解析模块的独立测试（ ≥ 50 份样本简历）。

子任务 3.3：人岗匹配诊断与差距分析

目标：进一步实现细粒度的人岗匹配，支持用户输入简历或技能信息后，系统自动匹配目标岗位、输出差距分析，并提供针对性改进建议与学习路径规划。

具体内容：构建多维度匹配算法，综合考虑技能匹配度、经验匹配度、行业匹配度、学历匹配度等维度进行加权评分；将简历解析结果与知识图谱中的岗位能力要求进行对比，识别技能缺失项、技能过剩项和技能匹配项；基于差距分析结果，利用大模型生成针对性的改进建议（如推荐学习课程、认证考试、项目实践方向等）和学习路径规划（含时间线与里程碑）；支持多目标岗位对比分析。

考核指标：人岗匹配准确率 $\geq 90\%$ （基于人工匹配结果进行评估）；差距分析覆盖技能缺失/过剩/匹配三个维度；改进建议生成覆盖率 100%（每个差距项均有对应建议）；学习路径规划包含 ≥ 3 个阶段的学习计划；匹配结果展示清晰、易于理解。

子任务 3.4：系统集成、测试与优化

目标：完成全系统的前后端集成、功能测试、性能优化与用户体验打磨，确保系统可正常部署运行。

具体内容：开发 Web 前端界面，包括岗位全景图谱可视化（热力图、时间序列图表、网络图谱、柱状图/饼图、地理分布图等）、人岗匹配交互界面、简历上传与结果展示界面；进行全流程集成测试，确保"数据采集 → 信息抽取 → 图谱构建 → 动态分析 → 简历解析 → 人岗匹配"全链路闭环；编写单元测试（覆盖率 $\geq 60\%$ ），完成系统性能优化（页面加载 ≤ 3 秒、API 响应 ≤ 2 秒）；准备竞赛提交材料：设计实现方案文档、PPT、演示视频（10 分钟以内）、部署说明（Dockerfile）。

考核指标：全流程闭环系统可正常部署运行；单元测试覆盖率 $\geq 60\%$ ；系统核心页面加载时间 ≤ 3 秒；图谱可视化交互流畅（无明显卡顿）；完成 ≥ 100 条 JD 的完整测试方案（含测试用例与结果报告）；完成演示视频录制与竞赛提交材料准备。

阶段交付物：集成系统（含 Docker 部署方案）、单元测试报告、竞赛提交全套材料（方案文档、PPT、演示视频、源码、测试数据）。

六、里程碑与时间总览

阶段	时间	核心里程碑	关键交付物
第一阶段	第 1 个月 (2026.06)	数据采集流水线上线，系统架构搭建完成	数据集、架构设计文档、基础设施环境
第二阶段	第 2 个月 (2026.07)	知识图谱构建完成，新岗位发现与能力更新功能可用	Neo4j 图谱、信息抽取模型、图谱查询说明报告
第三阶段	第 3 个月 (2026.08)	全流程闭环系统完成，竞赛材料准备就绪	集成系统、测试报告、演示视频、全套提交材料